

1. Introducció

1.1 Context

La indústria farmacèutica opera sota un marc regulatori estricte (GxP, GMP) que exigeix traçabilitat, reproductibilitat i documentació exhaustiva de tots els processos. Tradicionalment, la Root Cause Analysis (RCA) s'ha realitzat mitjançant mètodes qualitius com Ishikawa, 5 Whys o FMEA, que depenen fortament de l'experiència dels experts i presenten limitacions en entorns amb centenars de variables correlacionades.

L'avenç del Machine Learning interpretable obre la porta a una RCA data-driven que complementi el coneixement expert, permetent identificar patrons ocults en dades històriques de producció i quantificar l'impacte real de cada variable sobre el rendiment del procés.

1.2 Objectiu general

Dissenyar i avaluar una metodologia industrialitzable de Root Cause Analysis basada en models de Machine Learning interpretable, aplicable a entorns farmacèutics regulats (GxP).

1.3 Objectius específics

1. **OE1:** Construir un pipeline robust de neteja i preparació de dades de producció farmacèutica (960 mostres de 4.600 disponibles, 150 variables → 56 post-neteja).
2. **OE2:** Desenvolupar i validar un model EBM (Explainable Boosting Machine) amb metodologia en 4 fases (additiu → poda → interaccions → validació hiperparàmetres) que superi el baseline Lasso.
3. **OE3:** Generar explicacions interpretables (shape functions, rangs òptims) validables per experts de planta.
4. **OE4:** Construir un MVP Streamlit que permeti RCA interactiva amb simulació What-If i impacte financer.
5. **OE5:** Avaluar la viabilitat d'industrialització de la metodologia dins del marc GxP/GAMP 5.

1.4 Cas d'ús

El projecte s'aplica al procés de fraccionament de plasma humà mitjançant el mètode de Cohn, específicament a la Fracció II+III per a l'obtenció d'immunoglobulina G (IgG). La variable objectiu és el **yield D49** (rendiment de la fase D), un indicador crític de l'eficiència del procés que impacta directament en la rendibilitat econòmica de la planta.

El mètode de Cohn consisteix en la precipitació seqüencial de proteïnes plasmàtiques mitjançant variacions controlades de concentració d'etanol, pH, temperatura i força iònica. Les fases del procés inclouen:

- **Fase B:** Crioprecipitat
- **Fase C:** Fracció I (fibrinogen)
- **Fase D:** Fracció II+III (IgG)

1.5 Abast

- **Dedicació:** 300 hores
- **Lliurable principal:** Pipeline de dades + capa analítica + MVP interactiu
- **Naturalesa:** Validació conceptual (proof of concept) industrialitzable
- **Limitació:** No inclou desplegament en producció ni validació formal IQ/OQ/PQ

1.6 Arquitectura de 5 capes

Capa	Funció	Eines
1. Ingesta	Càrrega i unificació de dades	pandas, Excel
2. EDA	Exploració, neteja, selecció de variables	missingno, seaborn, scipy
3. Modelització	Entrenament i validació de models	InterpretML, scikit-learn
4. Explicabilitat	Shape functions, interaccions, RCA	InterpretML, plotly
5. Validació GxP	Documentació, traçabilitat, ALCOA+	Streamlit, markdown

1.7 Metodologia en 4 fases

La modelització segueix una estratègia progressiva en 4 fases:

1. **Fase 1:** EBM additiu (sense interaccions) per establir importàncies individuals
2. **Fase 2:** Feature pruning a top-15 variables (mètode del colze)
3. **Fase 3:** EBM amb interaccions detectades per algorisme FAST
4. **Fase 4:** Validació d'hiperparàmetres amb 7 configuracions comparades

1.8 Conclusions i treball futur

El model EBM Robust final assoleix $R^2=0.422\pm0.109$ amb explicabilitat nativa compatible amb entorns GxP. El business case demostra un impacte potencial de 5-27 M\$/any. Com a treball futur es proposa: validació formal GxP (IQ/OQ/PQ), expansió temporal del dataset, monitoratge de drift i integració operacional amb sistemes MES/LIMS.