

5. Especificacions de dades

5.1 Descripció del dataset

Característica	Valor
Total lots disponibles	4.600 (9 anys d'historial de producció)
Lots utilitzats per entrenament	960 (des de 2024+, per canvi de procés i no-estacionarietat)
Nombre de variables originals	150 paràmetres (104 numèriques + 46 categòriques)
Variables post-neteja	56
Font	Sistema de control de procés (DCS/LIMS)
Format original	Excel (.xlsx)
Variable objectiu	D49 (yield Fracció II+III)

Entorn tecnològic

Component	Versió
Python	3.9
InterpretML	0.4.3
scikit-learn	1.2.0

5.2 Fases del procés representades

Fase	Prefix	Descripció	Variables
B	B*	Crioprecipitat	Temperatures, temps, volums
C	C*	Fracció I (fibrinogen)	pH, etanol, precipitació
D	D*	Fracció II+III (IgG)	Paràmetres crítics de rendiment

5.3 Tipus de variables

Tipus	Descripció	Exemples	Tractament
Numèriques contínues	Mesures de procés	Temperatures, pH, concentracions	Estandardització
Categòriques	Equips, lots, operadors	Línia producció, tanc	One-hot (Lasso) / Natiu (EBM)
Temporals	Dates, torns	Data producció, torn	Eliminades (evitar data leakage)

Nota sobre feature engineering: Les marques temporals del procés es transformen en duracions agregades (p.ex., temps total de fase) en lloc d'usar timestamps directes, evitant data leakage i aportant informació operativa rellevant.

5.4 Pipeline de neteja de dades

Pas 1: Eliminació per missing values

- **Criteri:** Variables amb >35% de valors faltants són eliminades
- **Justificació:** Imputació amb tant missing introdueix massa soroll

Pas 2: Filtre de variància

- **Criteri:** Variables amb variància <0.10 són eliminades
- **Justificació:** Variables quasi-constants no aporten informació discriminatòria

Pas 3: Filtre de correlació

- **Criteri:** Parells de variables amb correlació >0.90 , s'elimina la de menor correlació amb D49
- **Justificació:** Reduir multicolinealitat sense perdre informació rellevant

Pas 4: Tractament de valors faltants residuals

- **Numèriques:** Imputació per mediana
- **Categòriques:** Categoria "Missing" explícita

5.5 Tractament de variables categòriques

Model	Estratègia	Justificació
Lasso	One-hot encoding	Requeriment del model lineal
EBM	Tractament natiu	EBM gestiona categòriques internament sense necessitat de transformació

5.6 Dataset resultant post-neteja

Etapla	Variables	Mostres
Original	150 (104 numèriques + 46 categòriques)	960
Post missing filter	~120	960
Post variància filter	~100	960
Post correlació filter	~56	960
Dataset final modelització	56	960