

6. Anàlisi i disseny

6.1 Arquitectura de 5 capes

Capa	Responsabilitat	Entrada	Sortida
1. Ingesta	Càrrega i unificació	Fitxers Excel	DataFrame unificat
2. EDA	Neteja i selecció	DataFrame brut	Dataset net, variables seleccionades
3. Modelització	Entrenament i validació	Dataset net	Model entrenat, mètriques
4. Explicabilitat	Interpretació	Model entrenat	Shape functions, rangs òptims, RCA
5. Validació GxP	Documentació i traçabilitat	Tot l'anterior	MVP interactiu, informes

6.2 Metodologia en 4 Fases

Fase 1: EBM additiu (baseline)

- Entrenament d'un EBM sense interaccions (interactions=0)
- Hiperparàmetres: min_samples_leaf=2, lr=0.05, max_bins=256, max_rounds=5000
- Avaluació de la importància de cada variable individualment
- Resultat: MAE=1.072, RMSE=1.602, R²=0.368

Fase 2: Feature pruning (poda top-15)

- Selecció de les 15 variables més importants de la Fase 1 (mètode del colze sobre ranking d'importància)
- Reducció de dimensionalitat per evitar overfitting
- Validació que el rendiment es manté amb menys variables

Fase 3: EBM amb interaccions

- Entrenament d'un EBM amb interactions=10, min_samples_leaf=10, top-15 features
- Interaccions detectades per algorisme FAST (fins a 25 en validació)

- Resultat: MAE=1.018, RMSE=1.466, R²=0.470

Fase 4: Validació d'hiperparàmetres

- Comparació de 7 configuracions amb 5-fold CV per seleccionar el millor tradeoff precisió/estabilitat
- Configuració seleccionada: **Robust (Leaf=10)** per millor precisió i menor variabilitat

Configuració	MAE±std	RMSE±std	R ² ±std
Robust (Leaf=10)	0.950±0.063	1.368±0.153	0.422±0.109
High Interactions (25)	0.953±0.057	1.370±0.136	0.421±0.094
Current Best	0.953±0.060	1.371±0.154	0.420±0.107
High Precision (512 bins)	0.954±0.058	1.371±0.149	0.420±0.103
Slow Deep Learning	0.954±0.068	1.381±0.155	0.412±0.105
Smooth Sensors (128 bins)	0.956±0.059	1.378±0.149	0.415±0.101
Simple/Stable	0.963±0.069	1.411±0.162	0.387±0.108

6.3 Hiperparàmetres del model EBM final (Robust)

Paràmetre	Fase 1	Fase 3/4 (final)	Justificació
max_bins	256	256	Granularitat suficient per a shape functions suaus
interactions	0	10	Detectades per algorisme FAST
learning_rate	0.05	0.05	Convergència adequada
max_rounds	5000	5000	Suficient per a convergència
min_samples_leaf	2	10	Fase 1: exploració; Final: robustesa
outer_bags	14	14	Estabilitat de les estimacions
inner_bags	4	4	Regularització interna

6.4 Validació: 5-fold Cross-Validation

- **Estratègia:** KFold amb k=5, shuffle=True, random_state fixat
- **Mètriques:** R², MAE, RMSE calculats en cada fold
- **Report:** Mitjana i desviació estàndard de cada mètrica
- **Objectiu:** Estimar rendiment generalitzable, detectar overfitting

6.5 Justificació del canvi de model

Model	R ²	MAE	Limitacions
Lasso (baseline)	0.33	1.12	Només relacions lineals, no captura interaccions
XGBoost (descartat)	~0.40	~0.98	Black-box, no compleix requisits GxP d'explicabilitat
EBM (seleccionat)	0.42	0.95	Glass-box, shape functions, interaccions interpretables

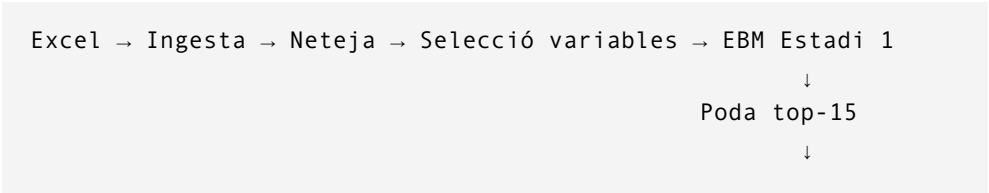
Justificació final: L'EBM ofereix el millor equilibri entre rendiment predictiu i explicabilitat nativa, requisit fonamental per a l'adopció en entorns GxP.

6.6 Disseny del MVP Streamlit

Mòduls

Mòdul	Funció
1. Dataset Overview	Visió general de les dades, estadístiques descriptives
2. Variable Analysis	Shape functions individuals, rangs òptims
3. Model Performance	Mètriques, prediccions vs real, residus
4. Root Cause Analysis	RCA per lot individual, waterfall contributions
5. What-If Simulator	Simulació d'escenaris canviant variables
6. Financial Impact	Impacte econòmic de millores proposades

6.7 Flux de dades



EBM Estadi 3 (interaccions)



Shape functions + RCA + What-If



MVP Streamlit (6 mòduls)