

7. Implementació

7.1 Estructura versionada del codi

El projecte segueix una estructura de versionat incremental que reflecteix l'evolució iterativa de la metodologia:

v0.2_exploracioEDA/

Primers scripts de neteja i anàlisi exploratori de dades (EDA). Conté un notebook d'exploració amb visualitzacions de valors faltants (missingno), distribucions de variables, matrius de correlació i anàlisi de la variable objectiu D49. Aquesta versió estableix la base per a la comprensió del dataset i identifica els principals reptes de qualitat de dades.

v0.3_lasso_baseline/

Model Lasso com a baseline del projecte. Notebook amb el pipeline complet de neteja de dades, entrenament del model Lasso amb regularització L1 i validació creuada 5-fold. Resultats: R^2 aproximat de 0.33, MAE de 1.12. Serveix com a punt de referència per avaluar millores posteriors i demostra les limitacions dels models lineals per a aquest problema.

v0.4_ebm_filter_interact/

Pivot metodològic a Explainable Boosting Machines (EBM). Notebook amb l'estratègia Filter-then-Interact completa en 4 fases: Fase 1 amb EBM additiu ($\text{min_samples_leaf}=2$, $\text{interactions}=0$), Fase 2 amb poda a top-15 variables, Fase 3 amb interaccions (FAST algorithm) i Fase 4 amb validació d'hiperparàmetres (7 configuracions). Resultats finals: $R^2=0.422\pm0.109$, $\text{MAE}=0.950\pm0.063$. Inclou les shape functions i la validació de la millora respecte al baseline.

v0.7_mvp_streamlit/

Primer MVP funcional amb interfície Streamlit. Aplicació web interactiva amb els mòduls de Root Cause Analysis, visualització de shape functions i simulador What-If. Permet als experts de planta explorar els resultats del model de forma intuïtiva i validar els descobriments amb el seu coneixement de procés.

v1.0_final/

Versió final completa del projecte amb totes les funcionalitats implementades. Inclou el business case amb impacte financer (Escenari A i B), optimitzacions de rendiment, els sis mòduls del MVP complets i la documentació associada. Aquesta versió constitueix el lliurable final del TFG.

7.2 Dependències principals

El fitxer `requirements.txt` defineix les dependències del projecte:

Paquet	Versió	Ús
pandas	>=2.0	Manipulació de dades
numpy	>=1.24	Càlcul numèric
scikit-learn	1.2.0	Pipeline ML, mètriques, Lasso
interpret	0.4.3	InterpretML, EBM
streamlit	>=1.28	Interfície web MVP
plotly	>=5.15	Visualitzacions interactives
openpyxl	>=3.1	Lectura fitxers Excel
missingno	>=0.5	Visualització missing values
seaborn	>=0.12	Visualitzacions estadístiques

7.3 Guia d'instal·lació

Requisits previs

- Python 3.9
- macOS / Linux / Windows
- 8GB RAM mínim recomanat

Passos d'instal·lació

1. Clonar el repositori
2. Crear entorn virtual: `python -m venv .venv`
3. Activar entorn: `source .venv/bin/activate`
4. Instal·lar dependències: `pip install -r requirements.txt`
5. Executar MVP: `streamlit run app.py`

Configuració

- Les dades s'esperen al directori `data/`
- La configuració de variables es troba a `data/variable_descriptions.json`
- La configuració d'anàlisi es troba a `data/variable_analysis_config.json`

7.4 Manual d'usuari del MVP

Panell lateral (Sidebar)

- Selecció de dataset
- Configuració de paràmetres del model
- Filtres de dades

Mòdul 1: Dataset Overview

- Estadístiques descriptives generals
- Distribució de la variable objectiu D49
- Resum de qualitat de dades

Mòdul 2: Variable Analysis

- Shape functions individuals per a cada variable
- Identificació de rangs òptims
- Contribució marginal de cada variable

Mòdul 3: Model Performance

- Mètriques de validació (R^2 , MAE, RMSE)
- Gràfic predicció vs valor real
- Anàlisi de residus

Mòdul 4: Root Cause Analysis (RCA)

- Selecció de lot individual
- Waterfall chart de contribucions
- Identificació de les variables amb major impacte positiu/negatiu
- Recomanacions d'acció

Mòdul 5: What-If Simulator

- Modificació interactiva de valors de variables
- Predicció en temps real del nou yield
- Comparació amb valor original
- Quantificació de la millora esperada

Mòdul 6: Financial Impact

- Traducció de millores de yield a impacte econòmic
- Escenaris A (global) i B (Pareto)
- Visualització del ROI per variable