

8. Resultats

8.1 Comparativa de models per fase

Fase	Model	MAE	RMSE	R ²
Baseline	Lasso	1.12	1.45	0.33
Fase 1	EBM additiu (interactions=0, leaf=2)	1.072	1.602	0.368
Fase 3	EBM interaccions (interactions=10, leaf=10)	1.018	1.466	0.470
Fase 4	EBM Robust (Leaf=10, final)	0.950±0.063	1.368±0.153	0.422±0.109

Fase 4: Comparació de 7 configuracions (5-fold CV)

Configuració	MAE±std	RMSE±std	R ² ±std
Robust (Leaf=10)	0.950±0.063	1.368±0.153	0.422±0.109
High Interactions (25)	0.953±0.057	1.370±0.136	0.421±0.094
Current Best	0.953±0.060	1.371±0.154	0.420±0.107
High Precision (512 bins)	0.954±0.058	1.371±0.149	0.420±0.103
Slow Deep Learning	0.954±0.068	1.381±0.155	0.412±0.105
Smooth Sensors (128 bins)	0.956±0.059	1.378±0.149	0.415±0.101
Simple/Stable	0.963±0.069	1.411±0.162	0.387±0.108

Millora relativa EBM Robust vs Lasso

Mètrica	Millora
MAE	-15.2%

Mètrica	Millora
RMSE	-5.7%
R ²	+27.9% (absolut +0.09)

8.2 Top variables identificades

Ranking	Variable	Fase	Descripció	Tipus
1	D36	D	Paràmetre crític fase D	Numèrica
2	D24	D	Paràmetre de procés fase D	Numèrica
3	D40	D	Condició operativa fase D	Numèrica
4	D1	D	Paràmetre inicial fase D	Numèrica
5	C33	C	Paràmetre fase C amb impacte downstream	Numèrica

8.3 Descobriments clau

Bell curves (relacions no monòtones)

Diverses variables presenten una relació en forma de campana amb el yield D49, és a dir, existeix un **rang òptim** fora del qual el rendiment decreix. Això és impossible de capturar amb models lineals com Lasso i justifica el pivot a EBM.

Variables no accionables

Algunes de les variables més influents no són directament controlables per l'operador (p.ex., característiques del plasma d'entrada). Això és rellevant per al business case, ja que limita la millora pràctica assolible.

Rangs òptims

Per a cada variable del top-15, les shape functions permeten identificar el rang de valors que maximitza el yield. Aquests rangs constitueixen la base de les recomanacions operatives.

Interaccions rellevants

El model EBM detecta interaccions significatives entre variables de diferents fases (p.ex., CxD), demostrant que l'optimització d'una fase depèn del que ha passat en fases anteriors.

8.4 Business case

Escenari A: Millora global

- **Hipòtesi:** Totes les variables es porten al seu rang òptim
- **Yield actual:** 46.31% → **Yield objectiu:** 47.32% (+1.01 pp)
- **Portafoli total:** 259M\$
- **Proteïna addicional:** 4.703 kg
- **Impacte econòmic:** 26.8 M\$/any (100 lots a 55\$/g)
- **Increment per lot:** 268.000\$
- **Viabilitat:** Teòrica, requereix control total de totes les variables

Escenari B: Millora Pareto (conservador)

- **Hipòtesi:** Només s'actua sobre les variables accionables del top-3: D36 (62.1%), D24 (50.4%), D40 (43.0%)
- **Millora yield:** +0.19 punts percentuals
- **Impacte econòmic:** ~5 M\$/any
- **Viabilitat:** Alta, variables directament controlables

Anàlisi de sensibilitat

- **Variació preu ±10%:** ±2.68 M\$/any
- **Coeficient de conservadorisme:** $29.4\% = R^2(0.422) \times \text{rec}(0.70)$
- **3 escenaris de cost d'implementació:** 1M\$, 5M\$, 15M\$ — tots amb ROI positiu

Justificació dels escenaris

L'Escenari B representa el retorn mínim esperable amb una implementació conservadora. La diferència entre A i B reflecteix la proporció de variables no accionables dins del model.

8.5 Validació amb experts

Els resultats han estat validats amb enginyers de procés de la planta:

- **D36 i D24:** Confirmats com a paràmetres crítics coneguts
- **Bell curves:** Coherents amb el coneixement de procés
- **C33:** Descobriment nou - l'impacte d'aquesta variable de fase C no era ben quantificat
- **Rangs òptims:** Dins dels límits operatius permesos per les especificacions de procés
- **Conclusió dels experts:** El model captura correctament la física del procés i aporta quantificació útil

8.6 Comparació amb RCA tradicional

Aspecte	RCA tradicional (Ishikawa/5 Whys)	RCA data-driven (EBM)
Escalabilitat	Limitada a poques variables	150 variables simultàniament
Objectivitat	Depèn de l'expert	Quantificació estadística
Interaccions	Difícil de detectar	Detecció automàtica (FAST)
Reproductibilitat	Baixa	Alta (model determinístic)
Temps d'anàlisi	Dies/setmanes	Minuts (MVP interactiu)
Limitació principal	Subjectivitat	Naturalesa observacional (no causal)

8.7 Limitacions

1. **Dataset limitat:** 956 mostres disponibles per entrenament, insuficients per capturar tota la variabilitat del procés
2. **Dependència de la qualitat dels logs operacionals:** El model és tan bo com les dades d'entrada
3. **Risc de drift:** Canvis de procés futurs poden invalidar el model (no-estacionarietat)
4. **Naturalesa observacional:** Les relacions identificades són correlacionals, no causals
5. **Gap d'implementació:** Integració amb sistemes GMP/QMS requereix validació formal addicional

8.8 Conclusions i Treball Futur

Conclusions

- L'EBM Robust ($R^2=0.422\pm0.109$) supera el baseline Lasso i ofereix explicabilitat nativa compatible amb GxP
- Les shape functions permeten identificar rangs òptims operatius per a cada variable
- El business case demostra un impacte potencial de 5-27 M\$/any segons l'escenari
- La metodologia en 4 fases és reproduïble i industrialitzable

Treball futur

1. **Validació formal GxP (IQ/OQ/PQ):** Qualificació completa del sistema per a ús en producció
2. **Qualitat de dades i expansió temporal:** Incorporar més lots i millorar la qualitat dels registres
3. **Monitoratge i governança:** Detecció de drift, recalibració periòdica del model
4. **Integració operacional:** Connexió amb sistemes MES/LIMS, workflows CAPA automatitzats