

# 10. Annexos

## Annex A: requirements.txt

```
pandas>=2.0
numpy>=1.24
scikit-learn==1.2.0
interpret==0.4.3
streamlit>=1.28
plotly>=5.15
openpyxl>=3.1
missingno>=0.5
seaborn>=0.12
matplotlib>=3.7
scipy>=1.11
```

## Annex B: Entorn de desenvolupament

| Component           | Versió / Detall        |
|---------------------|------------------------|
| Python              | 3.9                    |
| Sistema operatiu    | macOS (Darwin 25.5.0)  |
| Entorn virtual      | .venv (venv estàndard) |
| IDE                 | Visual Studio Code     |
| Control de versions | Git + GitHub           |
| Shell               | zsh                    |

## Estructura de directoris principal

```
ai_everything_20260128/
├─ app.py                # Aplicació principal Streamlit
├─ app_filter.py         # Mòdul de filtrat
├─ data/
│   └─ variable_descriptions.json # Descripcions de variables
│   └─ variable_analysis_config.json # Configuració d'anàlisi
├─ requirements.txt      # Dependències
├─ .venv/               # Entorn virtual
└─ dossier/             # Documentació del dossier
```

## Annex C: Declaració d'ús d'Intel·ligència Artificial

En compliment amb la normativa acadèmica, es declara l'ús de les següents eines d'IA durant el desenvolupament del projecte:

| Eina           | Proveïdor     | Ús principal                                                                            |
|----------------|---------------|-----------------------------------------------------------------------------------------|
| Perplexity Pro | Perplexity AI | Recerca bibliogràfica, revisió estat de l'art, consultes tècniques sobre regulació GxP  |
| Claude         | Anthropic     | Assistència en desenvolupament de codi, revisió d'estructura, generació de documentació |
| Gemini         | Google        | Consultes complementàries, contrast d'informació                                        |

### Principis d'ús

- Les eines d'IA s'han utilitzat com a **assistents**, mai com a generadors autònoms de contingut
- Tot el codi ha estat revisat, entès i validat per l'autor
- Les decisions de disseny i metodològiques són pròpies de l'autor
- La interpretació de resultats i conclusions són exclusivament de l'autor
- L'ús d'IA ha permès accelerar tasques repetitives i millorar la qualitat del codi

## Annex D: Bibliografia

[1] Anonymous. Recent advances and evaluation trends in explainable boosting machines, 2025. arXiv:2512.00528.

[2] Verónica Bolón-Canedo et al. A review of feature selection methods on synthetic data. arXiv:1507.08492, 2015.

[3] Thierry Burnouf. Modern plasma fractionation. *Transfusion Medicine Reviews*, 21(2):101-117, 2007.

[4] Rich Caruana, Yin Lou, Johannes Gehrke, Paul Koch, Marc Sturm, and Noemie Elhadad. Intelligible models for healthcare. *Proc. 21st ACM SIGKDD*, 2015.

[5] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. *Proc. 22nd ACM SIGKDD*, 2016.

- [6] E. J. Cohn, L. E. Strong, W. L. Hughes, D. J. Mulford, J. N. Ashworth, M. Melin, and H. L. Taylor. Preparation and properties of serum and plasma proteins. iv. *JACS*, 68(3):459-475, 1946.
- [7] Finale Doshi-Velez and Been Kim. Towards a rigorous science of interpretable machine learning. arXiv:1702.08608, 2017.
- [8] Isabelle Guyon and Andre Elisseeff. An introduction to variable and feature selection. *JMLR*, 3:1157-1182, 2003.
- [9] Trevor J. Hastie and Robert J. Tibshirani. *Generalized Additive Models*. Chapman and Hall, 1990.
- [10] ISPE. *GAMP 5: A Risk-Based Approach to Compliant GxP Computerized Systems*. 2022.
- [11] et al. Liu. Investigating and imputing missing data in industrial datasets. arXiv:2106.12345, 2021.
- [12] Yin Lou, Rich Caruana, Johannes Gehrke, and Giles Hooker. Accurate intelligible models with pairwise interactions. *Proc. 19th ACM SIGKDD*, 2013.
- [13] Jie Lu, Anjin Liu, Fan Dong, Feng Gu, João Gama, and Guangquan Zhang. Learning under concept drift: A review. arXiv:2004.05785, 2020.
- [14] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. arXiv:1705.07874, 2017.
- [15] Scott M. Lundberg, Su-In Lee. SHAP. *Advances in Neural Information Processing Systems*, 30, 2017.
- [16] Harsha Nori, Samuel Jenkins, Paul Koch, and Rich Caruana. Intelligible models for healthcare. *Proc. 25th ACM SIGKDD*, 2019.
- [17] Harsha Nori, Samuel Jenkins, Paul Koch, and Rich Caruana. InterpretML: A unified framework. arXiv:1909.09223, 2019.
- [18] PiML Team. Piml toolbox: Explainable boosting machine (ebm) guide. 2025.
- [19] Anurag S. Rathore and Helen Winkle. Quality by design for biopharmaceuticals. *Nature Biotechnology*, 27(1):26-34, 2009.
- [20] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "Why should I trust you?". arXiv:1602.04938, 2016.
- [21] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. LIME. *Proc. 22nd ACM SIGKDD*, 2016.

[22] Cynthia Rudin, Ching-Hsiang Chen, Zhi Chen, Han Huang, Lesia Semenova, and Chudi Zhong. Interpretable machine learning: 10 grand challenges. arXiv:2103.11251, 2021.

[23] U.S. Food and Drug Administration. *Data Integrity and Compliance With Drug CGMP*. FDA, 2018.

## Annex E: Informes lliurats

| # | Informe              | Data lliurament | Contingut principal                         |
|---|----------------------|-----------------|---------------------------------------------|
| 1 | Informe Inicial      | 2026-01-28      | Definició projecte, objectius, planificació |
| 2 | Informe de Progrés 1 | 2026-03-27      | EDA, Lasso, pivot EBM, primers resultats    |
| 3 | Informe de Progrés 2 | 2026-04-25      | Business case, MVP, validació experts       |