

Informe de Progrés II: Treball Final de Grau

1. Introducció i Estat d'Avenç Global

Aquest segon informe de progrés detalla l'estat d'evolució i consolidació del Treball Final de Grau (TFG). Després de superar les fases inicials de preprocessament i de fixar l'estratègia de modelització basada en *Explainable Boosting Machines* (EBM) mitjançant l'enfocament *Filter-then-Interact*, el projecte ha avançat directament cap a la seva fase de validació econòmica, operativa i de transferència tecnològica.

En aquest estadi, s'ha assolit l'anàlisi d'explicabilitat aplicat a un cas d'estudi industrial altament complex i regulat: el procés de fraccionament de plasma humà per a l'obtenció de proteïnes terapèutiques d'alt valor. Així mateix, s'ha validat empíricament la viabilitat del projecte mitjançant la formulació d'un *business case* basat en dades històriques post-canvi, i s'ha desenvolupat un Producte Mínim Viable (MVP) utilitzant Streamlit per dotar el sistema d'una interfície d'usuari interactiva i accessible per als enginyers de planta.

2. Estat d'Assoliment dels Objectius

- **Objectiu 1: Explorar, preparar i modelitzar dades farmacèutiques.**
 - *Estat:* Completat. Neteja, enginyeria de característiques i anàlisi exploratòria (EDA) d'un conjunt complex de 150 variables de procés completat amb èxit.
- **Objectiu 2: Estudiar i aplicar tècniques de Machine Learning per a RCA.**
 - *Estat:* Completat. Pivotatge consolidat cap a l'arquitectura *Filter-then-Interact* amb models EBM, superant la linealitat de LASSO i descartant l'opacitat de XGBoost per complir amb les directrius GxP.
- **Objectiu 3: Avaluar la interpretabilitat, robustesa i fiabilitat (RCA).**
 - *Estat:* Completat. S'han extret i validat amb experts de procés les funcions de forma (*shape plots*) i les contribucions de les variables aplicades al cas d'ús del plasma, identificant comportaments crítics no lineals.
- **Objectiu 4: Analitzar la integració en fluxos GxP i Validació del Business Case.**
 - *Estat:* *Completat.* S'ha formulat la justificació financera rigorosa del projecte utilitzant un enfocament matemàtic conservador, alineant els resultats amb els requisits de data integrity (ALCOA+) i GAMP 5.
- **Objectiu 5 (Nou / Transversal): Desenvolupament de la interfície d'usuari (MVP).**
 - *Estat:* En curs. Programació d'una eina web operativa en Streamlit per fer transferència de tecnologia cap a l'usuari final (Planta/Qualitat).

3. Desenvolupament de l'Activitat i Resultats

3.1. Aplicació i Explicabilitat en el Procés de Fraccionament de Plasma

El cas d'estudi aborda el procés de fraccionament industrial de plasma humà basat en el mètode clàssic d'etanol en fred de Cohn. Aquest mètode utilitza modificacions sistemàtiques i rigoroses de pH, temperatura i concentració d'etanol per separar les proteïnes plasmàtiques. Específicament, l'anàlisi d'aquest treball s'ha focalitzat en el flux de producció fins a l'obtenció de la **Fracció II+III**, etapa crítica on es concentra la major part de les immunoglobulines (IgG).

El tram s'ha estructurat en tres fases operatives integrades en el pipeline de dades:

1. **Separació inicial:** Descongelació del plasma i recuperació del crioprecipitat, on variables com l'edat del plasma i el temps de barreja (*pooling*) introdueixen la primera font de variabilitat.
2. **Precipitació de proteïnes:** Separació de les Fraccions I i II+III, on el control del pH, el temps de mescla i la dosificació d'etanol són vitals.
3. **Filtració i recuperació:** Executada mitjançant filtres premsa, la qual determina directament el rendiment final (*yield*) d'IgG.

A causa de la naturalesa biològica de la matèria primera, el procés experimenta fluctuacions elevades. Mitjançant el model EBM configurat com a Robust (Leaf 10) i validat amb una estratègia de validació creuada de 5 talls (5-fold CV), s'han assolit unes mètriques estables fora de mostra de $R^2 = 0,42$ i un $MAE = 0,95 \pm 0,07$.

L'anàlisi de gràfics de forma (*shape plots*) de l'EBM ha permès identificar comportaments no lineals clau. En lloc de relacions lineals pures, paràmetres com el temps de filtració o determinades inèrcies químiques presenten geometries en forma de campana (*bell curves*), demostrant de forma gràfica als experts de procés que aquests paràmetres només són òptims dins d'un rang operacional tancat i que la filosofia de "com més gran, millor" és errònia en aquest entorn.

A més, el model ha revelat *insights* d'alt valor per a l'equip de Qualitat en identificar que variables inicialment indexades com a "no accionables" (p. ex., identificadors de tancs específics utilitzats per a la neteja o crioprecipitació) exhibeixen un pes predictiu i una descomposició de la contribució al rendiment final superior a la de variables que històricament es consideraven els únics *drivers* del procés.

Shape Function: D1 (Categorical)




Figura 1: *Shape function* (funció de forma) de la variable categòrica **D1** obtinguda mitjançant el model EBM. Les barres representen la contribució de cada categoria al rendiment final d'IgG (**D49**). Les línies verdes indiquen un impacte positiu (bon rendiment), mentre que les vermelles identifiquen categories altament subòptimes (causes arrel de baix rendiment), evidenciant desviaments de fins a $-\$0.7$ respecte a la línia base

Shape Function: C33




Figura 2: Shape function de la variable contínua C33 (paràmetre de procés) i la seva relació no lineal amb l'impacte en el yield (D49). L'estrella vermella identifica el punt operatiu òptim (al voltant d'un valor de 3), a partir del qual un increment en el valor de la característica penalitza progressivament el rendiment de la Fracció II+III, superant el llindar de soroll o impacte neutral

3.2. Validació i Disseny del Business Case

Per dotar el projecte de rigor industrial de cara a auditories de qualitat i comitès de direcció, s'ha desenvolupat una metodologia d'estimació del potencial optimitzat que defuig de les especulacions algorítmiques gràcies a l'arquitectura *glass-box*. L'EBM permet descompondre algebraicament cada lot com:

$$f(x) = \beta_0 + \sum f_i(x_i) + \sum f_{ij}(x_i, x_j).$$

A partir d'aquí, el potencial optimitzat de cada lot (Y_{opt}) es calcula castigant l'òptim teòric mitjançant la següent expressió matemàtica:

$$Y_{opt} = Y_{pred} + (-\sum Score_{neg} \times \eta_{rec} \times R^2)$$

On $-\sum Score_{neg}$ representa les contribucions negatives de factors subòptims (impacte <

-0,1 pp , i η_{rec} és el factor de recuperació operativa real de la planta fixat en un 70%

(penalització del 30% per friccions mecàniques, temps de resposta i inèrcies del procés).

Multiplicat per la variància explicada ($R^2 = 0,42$) com a factor de confiança estadística ,

s'obté un **coeficient de conservadorisme global del 29,4% - 29,6%**. A més, l'error absolut mitjà (MAE = 0,95) actua com a llindar de significació: només es computen senyals que superin el soroll del model, blindant el cas de negoci davant de fluctuacions aleatòries.

S'han avaluat dos escenaris econòmics principals basats en una cartera de 965 lots històrics del període post-canvi, assignant un preu de referència de 55 \$/g per a la proteïna objectiu:

- **Escenari A (Potencial Total del Portfolio):** Corregint de manera ideal tots els *negative drivers* operatius es podria incrementar el rendiment mitjà del 46,31% al 47,32%. Aquest guany absolut de +1,01 punts percentuals (millora relativa del 2,2%) generaria un increment de facturació mitjà de 268.000 \$ per lot. Per a una cadència estàndard de 100 lots, l'impacte recurrent anual estimat és de **26,8 milions de dòlars**. Aquest és un horitzó aspiracional limitat per restriccions físiques de la planta.
- **Escenari B (Estratègia Pareto Focalitzada):** En lloc d'intervenir en totes les variables, el model ha aïllat una ruta simplificada actuant únicament sobre 3 variables crítiques: **D36** (filtració, afecta el 62,1% dels lots), **D24** (mescla, 50,4%) i **D40** (filtració, 43,0%). Aquesta acció focalitzada captura instantàniament un guany de +0,19 punts percentuals de rendiment (el 19% del potencial total). Donat l'alt valor del producte biològic, aquesta estratègia d'esforç mínim de reajustament en planta reporta per si sola prop de **5 milions de dòlars anuals**, justificant immediatament el projecte.

Com a tancament, s'ha realitzat un anàlisi de sensibilitat davant els costos d'implementació del propi projecte:

1. *Escenari Conservador (~1 M\$/any):* El retorn de la inversió (ROI) és immediat i netament favorable.
2. *Escenari Intermedi (~5 M\$/any):* Continua essent clarament positiu, validant i justificant folgadamente l'estratègia focalitzada de Pareto (Escenari B).
3. *Escenari Exigent (~15 M\$/any):* El projecte manté un retorn net positiu tot i la contracció del marge.

El cas de negoci demostra una robustesa elevada davant variacions de mercat i una viabilitat financera plenament assegurada.

3.3. Desenvolupament del Primer MVP amb Streamlit

Amb l'objectiu de transferir aquests models a la realitat operativa sota directrius de validació conceptual de suport a la decisió (GAMP 5), s'ha dissenyat i programat un primer MVP interactiu utilitzant **Streamlit**. Aquesta interfície web permet traduir el pipeline de dades en pantalles d'acció directa per als enginyers de planta:

- **Panell de Monitorització de Lots:** Visualització en temps real del rendiment (*yield*) real i predictiu de la Fracció II+III.
- **Mòdul d'Anàlisi de Causa Arrel (RCA):** Mitjançant la descomposició exacta de les puntuacions (*scores*) de l'EBM, l'usuari pot seleccionar un lot amb rendiment anòmal i obtenir de manera interactiva la llista prioritzada d'hipòtesis i variables (p. ex., un excés de temps de barreja o un desviament de pH en la fase 2) que han causat la pèrdua de producte.
- **Simulador Operatiu (What-If Analysis):** Una secció interactiva equipada amb controls lliscants (*sliders*) on els enginyers de planta poden alterar artificialment els valors de les variables crítiques (com D36 o D24) i visualitzar instantàniament com es comportaria la predicció del rendiment segons l'EBM abans d'executar el lot físic.

5. EBM Filter-Then-Interact Pipeline

Three-phase approach:

1. **Phase 1:** Train EBM with `interactions=0` to rank all features by main effects
2. **Phase 2:** Prune to top-N most important features
3. **Phase 3:** Re-train EBM on pruned features with interaction detection enabled

Configuration

EBM Hyperparameters (from notebook configuration)

Top-N Features to Keep (Phase 2) 15

Max Interaction Pairs (Phase 3) 10

Learning Rate 0,050

Max Bins 256

Max Rounds 5000

Min Samples Leaf 10

Number of Jobs 1

Random State 42

Train EBM Pipeline

Figura 3: Interfície de configuració de l'arquitectura *Filter-Then-Interact* implementada en el mòdul d'administració de l'MVP (Streamlit). Permet als usuaris controlar interactivament els hiperparàmetres de l'EBM (com el nombre de variables a retenir a la fase de filtre, el màxim de parelles d'interacció i el paràmetre de *Min Samples Leaf* fixat en 10), actuant com un entorn auditable i traçable sota paràmetres GxP abans d'executar el reentrenament del pipeline

Shape Functions: Feature Effect on D49 Yield




Figura 4: Visualització interactiva de la funció de forma (*Shape Function*) per a la característica categòrica **D1** dins de l'aplicació Streamlit. La interfície permet als operadors de planta identificar de manera directa quines categories de procés actuen com a *negative drivers* (barres vermelles, penalitzant el *yield* fins a -0,736 pp i quines maximitzen la recuperació d'IgG (barres verdes), facilitant la generació d'hipòtesis ràpides durant una investigació de causa arrel (RCA).





Figura 5: Mòdul de simulació d'escenaris (*What-If Analysis*) i impacte financer integrat a l'MVP. La pantalla mostra la traducció automàtica dels senyals del model en mètriques de negoci reals per a un lot seleccionat, calculant el guany esperat de rendiment +0,26 pp corregit pel coeficient de conservadorisme), la quantitat addicional de proteïna recuperada (+1,19 kg) i l'estimació de beneficis (+65.429\$) sotmesa a una matriu de sensibilitat del preu de mercat (50 \$/g, 55 \$/g i 60 \$/g).

4. Planificació, Seguiment i Desviacions

Respecte a la planificació inicial de 300 hores, el cronograma real manté un balanç global positiu i alineat amb els objectius establerts.

Les desviacions temporals experimentades durant les tasques T2 (Data Cleaning) i T3 (Anàlisi Exploratori) —provocades pel coll d'ampolla que va suposar la gestió de missing values i les entrevistes amb els enginyers de planta per entendre les correlacions de les 150 variables— s'han neutralitzat gràcies a l'acceleració en la tasca T4 (Modelatge). L'adopció de l'estratègia *Filter-then-Interact* amb llibreries natives d'EBM va simplificar de manera dràstica els cicles d'entrenament, eliminant la necessitat de mètodes d'optimització de hiperparàmetres complexos propis de models de caixa negra com XGBoost.

Actualment, el projecte es troba en la Fase III (Documentació i Redacció de la Memòria), i es preveu el lliurament del TFG dins dels terminis oficials de la universitat.



5. Conclusions i Propers Passos

Aquest segon període de progrés ha assolit la integració satisfactòria de la ciència de dades, el valor econòmic (ROI) i el context industrial de la fragmentació de plasma. S'ha validat que l'EBM actua de manera eficient com un assistent de decisió basat en evidència executable.

Els propers passos immediats abans de la defensa final del treball són:

1. **Tancar l'MVP en Streamlit:** Optimitzar el codi de visualització de gràfics per agilitzar la interacció de l'usuari.
2. **Redactar la proposta de validació conceptual GxP:** Establir de manera formal el disseny conceptual del pla de validació (matriu de traçabilitat de requeriments, governança i gestió de riscos de model en línia amb GAMP 5 i ALCOA+).
3. Consolidació i revisió d'estil de la Memòria Tècnica Final.

6. Declaració de l'Ús d'Intel·ligència Artificial Generativa

En compliment de les directrius ètiques i de transparència acadèmica de la universitat, es detalla a continuació l'ús que s'ha fet d'eines d'Intel·ligència Artificial (IA) generativa com a suport en les diferents fases de desenvolupament d'aquest Treball Final de Grau:

- **Recerca d'informació i documentació (Perplexity AI):** S'ha utilitzat aquesta plataforma de cerca conversacional per agilitzar la recopilació i contrast de documentació tècnica vinculada al procés de fraccionament de plasma humà i al mètode clàssic de Cohn. Així mateix, es va emprar per investigar, contrastar i validar de manera eficient diferents fonts d'informació de mercat relatives al preu de referència per gram de la immunoglobulina (IgG), fixant així una base sòlida i realista per al *business case*.
- **Desenvolupament de codi i anàlisi de dades (Claude - Anthropic):** S'ha fet servir com a assistent de programació en la creació del codi de l'aplicació interactiva (MVP) desenvolupada amb Streamlit. A més, es va utilitzar com a suport metodològic en el disseny dels scripts de Python integrats al *notebook* per automatitzar els càlculs algebraics de descomposició del model EBM i les simulacions dels escenaris de rendibilitat financera.
- **Redacció i consolidació de text (Gemini - Google):** S'ha utilitzat com a eina de suport a la redacció tècnica, estructuració de continguts i revisió d'estil de l'informe, ajudant a unificar el to acadèmic de les diferents seccions i a sintetitzar els resultats obtinguts.

7. Bibliografia

[1] H. Nori, S. Jenkins, P. Koch, and R. Caruana, "InterpretML: A unified framework for machine learning interpretability," *arXiv preprint arXiv:1909.09223*, 2019.

[2] Y. Lou, R. Caruana, J. Gehrke, and G. Hook, "Accurate intelligible models with pairwise interactions," in Proc. 19th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD), 2013, pp. 623–631.

[3] R. Caruana, Y. Lou, J. Gehrke, P. Koch, M. Sturm, and N. Elhadad, "Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission," in Proc. 21st ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD), 2015, pp. 1721–1730.

[4] T. Hastie and R. Tibshirani, *Generalized Additive Models*. Chapman & Hall, 1990.

[5] A. S. Rathore and H. Winkle, "Quality by design for biopharmaceuticals," *Nature Biotechnology*, vol. 27, no. 1, pp. 26–34, 2009.

[6] T. Burnouf, "Modern plasma fractionation," *Transfusion Medicine Reviews*, vol. 21, no. 2, pp. 101–117, 2007.

[7] E. J. Cohn, L. E. Strong, W. L. Hughes, D. J. Mulford, J. N. Ashworth, M. Melin, and H. L. Taylor, "Preparation and properties of serum and plasma proteins. IV. A system for the separation into fractions of the protein and lipoprotein components of biological tissues and fluids," *Journal of the American Chemical Society*, vol. 68, no. 3, pp. 459–475, 1946.

[8] F. España, P. Medina, S. Navarro, E. Zorio, A. Estellés, and J. Aznar, "The multifunctional protein C system," *Current Medicinal Chemistry: Cardiovascular & Hematological Agents*, vol. 3, no. 2, pp. 119–131, 2005.