

Informe de Progrés: Treball Final de Grau

1. Introducció

Aquest informe detalla l'estat d'avenç del Treball Final de Grau (TFG). Actualment, el projecte ha superat les fases crítiques de preparació de dades i modelització inicial, entrant en l'etapa d'explicabilitat i anàlisi de resultats. L'enfocament s'ha mantingut fidel a la resolució de problemes de causa arrel (RCA) mitjançant models *glass-box*.

2. Objectius

A continuació es detalla l'estat d'assoliment dels objectius definits:

- **Objectiu 1: Explorar, preparar i modelitzar dades farmacèutiques.**
 - **Estat:** Completat.
 - **Progrés:** S'ha finalitzat la neteja i l'EDA d'un conjunt complex de 150 variables.
- **Objectiu 2: Estudiar i aplicar tècniques de Machine Learning per a RCA.**
 - **Estat:** Completat.
 - **Canvis:** S'ha pivotat metodològicament cap a l'estratègia *Filter-then-Interact* amb models EBM, descartant l'ús d'XGBoost per la seva opacitat i el model LASSO per la seva menor capacitat predictiva en relació amb la complexitat del procés.
- **Objectiu 3: Avaluar la interpretabilitat, robustesa i fiabilitat (RCA).**
 - **Estat:** En curs.
 - **Progrés:** S'estan generant els gràfics d'explicabilitat (SHAP/LIME) i s'han validat resultats preliminars amb experts de procés.
- **Objectiu 4: Analitzar la integració en fluxos GxP.**
 - **Estat:** Pendent (Fase final).

3. Metodologia de treball

El present treball s'articula mitjançant una metodologia d'**investigació-acció iterativa**, dissenyada per abordar la complexitat i l'alta dimensionalitat de les dades farmacèutiques. Per garantir el rigor i la traçabilitat en un entorn regulat, s'ha definit un **pipeline sistemàtic** que estructura el flux de dades des de la seva captació fins a la generació d'accions correctives (RCA).


3.1 Pipeline del Sistema

El flux de treball es divideix en cinc etapes consecutives:

1. **Inputs (Entrades):**
 - Dades històriques de producció (5 anys).

- Conjunt de dades multivariant amb $n=150$ variables (paràmetres de procés, temperatures, temps, identificadors de tancs, etc.).
 - Variable objectiu (y): Rendiment del procés (*yield*).
2. **Preprocessament i Comprensió del Procés:**
- **Neteja de dades:** Tractament de *missing values* i eliminació de soroll.
 - **Enginyeria de característiques:** Identificació de variables categòriques i anàlisi de col·linealitat (ex: correlació entre pes final i *yield*).
 - **Validació amb experts:** Entrevistes amb enginyers de planta per contextualitzar les fases del procés i descartar variables trivials.
3. **Modelatge: Estratègia "Filter-then-Interact":**
- Aquesta és l'etapa central del treball, on s'utilitza un enfocament de dos estadis basat en **Explainable Boosting Machines (EBM)**:
- **Estadi 1 (Filtre):** S'entrena un model EBM purament additiu (sense interaccions) per calcular la importància de cada característica. Es seleccionen les top n variables amb més pes predictiu.
 - **Estadi 2 (Interacció):** S'entrena un segon model EBM que només permet interaccions per parelles (*pairwise interactions*) entre les variables filtrades a l'estadi anterior. Això evita l'explosió combinatòria i garanteix que les interaccions detectades tinguin coherència física.
4. **Validació:**
- Ajust d'hiperparàmetres per optimitzar la robustesa del model.
 - Benchmarking comparatiu de mètriques d'error (MAE) i coeficient de determinació (R^2) respecte a models base (LASSO, XGBoost).
 - Avaluació de la consistència dels resultats amb estudis històrics de la planta.
5. **Interpretació i RCA:**
- Anàlisi de **gràfics de forma** (*shape plots*) per identificar comportaments no lineals (ex: corbes de campana en variables accionables).
 - Priorització de causes arrel mitjançant la descomposició de la contribució de cada variable al resultat final.
 - Definició d'hipòtesis per a futures accions CAPA.

3.2 Esquema Visual del Flux Metodològic



3.3 Justificació del canvi de model

El pivotatge de l'estratègia inicial (LASSO + EBM) cap al **Filter-then-Interact** es justifica per la necessitat d'equilibrar la capacitat predictiva amb la interpretació clínica/industrial. Mentre que LASSO és eficaç per a la selecció lineal, l'EBM permet capturar relacions no lineals des de l'inici del pipeline, millorant el R^2 del **0.33** al **0.52** sense sacrificar la naturalesa *glass-box* del model, essencial en entorns GxP.

4. Planificació i seguiment


Respecte al cronograma inicial, el projecte presenta un avenç global positiu. Tot i mantenir-se dins del còmput total d'hores previstes (300 hores), la distribució interna del temps ha variat significativament per adaptar-se a les realitats tècniques del procés farmacèutic.

4.1. Estat general i desviacions detectades

L'evolució del treball ha estat marcada per dos fenòmens contraposats que han equilibrat el balanç temporal:

- **Desviacions en la fase inicial (T2 i T3):** La preparació de dades i la comprensió del procés de producció han requerit una inversió de temps superior a la pressupostada. La complexitat de les fases industrials, la dispersió de les fonts i l'elevat nombre de *missing values* en les 150 variables van actuar com un coll d'ampolla. Va ser necessari dedicar hores addicionals a entrevistes amb experts de planta per garantir que la neteja de dades no eliminés informació crítica.
- **Acceleració en la modelització (T4):** Un cop consolidada una base de dades neta i entès el procés, l'adopció de l'estratègia *Filter-then-Interact* amb models EBM va resultar ser molt més eficient que els enfocaments inicials (XGBoost/LASSO). Això va permetre escurçar els cicles d'entrenament i optimització, compensant el retard acumulat en les fases prèvies.

4.2. Diagrama de Gantt de l'estat actual del Timeline



5. Seguiment Qualitatiu del treball

Aquesta secció recull la reflexió crítica sobre els reptes trobats i les decisions preses:

Dificultats i Aprenentatge del Procés

L'obstacle principal no ha estat algorítmic, sinó de context. Amb 150 variables i una dependència crítica del *yield* (rendiment), va ser necessari realitzar una **immersió en el procés de producció**. Mitjançant entrevistes amb experts de la planta i revisió de literatura, es van identificar correlacions trivials (ex: pes final vs. yield) i es van distingir variables

categòriques d'alt impacte. També es va detectar un canvi radical en el *yield* durant els darrers 5 anys, fet que va obligar a contextualitzar les dades històriques abans de modelitzar.

Decisions Tècniques i Reflexió Crítica

1. **Abandonament de LASSO i XGBoost:** Tot i que LASSO i EBM donaven resultats similars (MAE i R^2) en escenaris de poques dades, l'EBM va demostrar ser molt superior a mesura que augmentàvem les observacions i reduïem dimensionalitat. XGBoost es va descartar perquè la seva complexitat no aportava millores significatives i dificultava l'objectiu principal: la interpretabilitat en entorns regulats.
2. **L'estratègia Filter-then-Interact:** Ha estat la decisió tècnica més exigent i encertada. Ha permès passar d'un R^2 de **0.33** (primer approach) a un de **0.47-0.52**, reduint el MAE de **1.4** a **0.98**.
3. **Insights Reals:** El model ha identificat variables "no accionables" (com els tancs específics utilitzats per a la neteja o cryo) amb més pes que variables "accionables" (com la temperatura en Fase 1). Aquest és un descobriment clau que obre noves hipòtesis de treball per a l'equip de qualitat.
4. **Detecció de no-linealitats:** L'ús de models *glass-box* ens ha permès visualitzar "bell curves" en variables on inicialment es pressuposava una relació lineal. S'ha demostrat que certs paràmetres només són òptims dins d'un rang concret i no "com més gran, millor".

6. Ús de la IA

L'ús d'IA generativa s'ha integrat com un suport a l'autoria per augmentar l'eficiència:

- **Perplexity:** Recerca i selecció de bibliografia sobre EBMs i GA²M.
- **Claude Code:** Assistència en l'optimització de codi de preprocessament i implementació del flux *filter-then-interact*.
- **Gemini:** Suport en l'estructuració i millora de l'estil de la redacció acadèmica de l'informe.
- **Recursos externs:** S'han seguit les millors pràctiques de repositoris de recerca (com els d'Andrej Karpathy) per garantir un codi net i eficient.

7. Bibliografia

[1] H. Nori et al., "InterpretML: A unified framework for machine learning interpretability," *arXiv preprint arXiv:1909.09223*, 2019.

[2] Y. Lou et al., "Accurate intelligible models with pairwise interactions," in *Proc. 19th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD)*, 2013, pp. 623–631.

[3] R. Caruana et al., "Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission," in *Proc. 21st ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD)*, 2015, pp. 1721–1730.

[4] T. Hastie and R. Tibshirani, *Generalized Additive Models*. Chapman & Hall, 1990.