

Disseny i avaluació d'una metodologia d'industrialització de la Root Cause Analysis (RCA) basada en models de Machine Learning

Arnau Garriga Torné

Curs 2025–2026

1 Resum

Aquest treball proposa i valida una metodologia d'industrialització de la Root Cause Analysis (RCA) basada en models de Machine Learning interpretables per a entorns farmacèutics regulats. La proposta s'estructura en cinc capes: anàlisi exploratòria, modelització predictiva, estratègia *filter-then-interact* amb Explainable Boosting Machines (EBM), capa d'explicabilitat i capa de validació i industrialització.

El conjunt de dades utilitzat per a la modelització inclou 956 mostres i 56 variables originals, amb validació creuada de 5 folds i criteris de robustesa orientats a ús operatiu. Es comparen diferents configuracions d'EBM per identificar el millor compromís entre precisió, estabilitat i interpretabilitat.

Els resultats mostren una millora progressiva respecte al baseline Lasso: reducció del 15.6% en MAE i del 16.9% en RMSE en la millor configuració de Fase 4. La configuració **Robust (Leaf=10)** obté el millor equilibri global (MAE = 0.950, RMSE = 1.368, $R^2 = 0.422$), mantenint estabilitat entre folds i facilitant la prioritització de factors crítics en RCA.

Com a contribució principal, el treball demostra que una estratègia EBM interpretable-by-design (interpretabilitat nativa) permet combinar rendiment predictiu, traçabilitat i utilitat operativa, i constitueix una base sòlida per a desplegament progressiu en entorns GMP/QMS amb monitoratge de *drift* i governança de cicle de vida del model.

Paraules clau: Root Cause Analysis, Explainable Boosting Machine, interpretabilitat, va-

lidació creuada, industrialització, qualitat farmacèutica.

2 Introducció i Objectius

La indústria farmacèutica opera sota requisits estrictes de qualitat i traçabilitat. Quan es detecta una desviació de procés o resultat fora d'especificació, cal activar una investigació de causes arrel (RCA) per identificar l'origen del problema i definir accions correctives. Malgrat la maduresa normativa del sector, aquestes investigacions continuen sent manuals i dependents de l'experiència, generant variabilitat entre investigadors, escalabilitat limitada i dificultat per garantir consistència temporal.

En aquest treball, el problema s'analitza en el context del fraccionament de plasma humà fins a l'obtenció de la Fracció II+III, un procés farmacèutic multietapa especialment sensible a variacions fisicoquímiques i operatives. Aquesta complexitat fa que petites desviacions de procés puguin traduir-se en impactes rellevants sobre el *yield* i els atributs crítics de qualitat, reforçant l'interès d'una aproximació RCA assistida per dades [6, 3].

L'aparició de tècniques de Machine Learning i mètodes d'explicabilitat (XAI) permet una RCA més sistemàtica i basada en dades [14, 20, 7]. Aquest treball proposa una metodologia d'**industrialització de la RCA basada en ML interpretable** per augmentar el criteri expert amb evidència quantitativa prioritzada, reduint l'espai d'hipòtesis i millorant la velocitat d'investigació. La proposta integra preparació de dades, modelització amb Explainable

Boosting Machines (EBM), explicabilitat nativa i validació orientada a entorns regulats GxP.

Objectius: (1) Definir un marc RCA data-driven alineat amb requisits GxP; (2) Construir un pipeline de dades reproduïble; (3) Desenvolupar models ML interpretables per predir desviacions; (4) Aplicar tècniques d'explicabilitat per prioritzar hipòtesis de causa arrel; (5) Proposar una arquitectura d'industrialització i validació per a integració progressiva en operació.

3 Estat de l'art

3.1 RCA tradicional i limitacions en entorns data-rich

Les metodologies clàssiques de RCA (5 Whys, Ishikawa, FMEA) han estat àmpliament utilitzades en la indústria farmacèutica per estructurar investigacions de desviació. Tanmateix, diversos treballs evidencien limitacions quan el volum i heterogeneïtat de dades augmenten: dependència elevada del coneixement tàcit, baixa repetibilitat entre equips i dificultat per capturar interaccions multivariants complexes.

En entorns GxP, l'RCA requereix evidència auditable i justificació de decisions. Per això, l'objectiu no és automatitzar la decisió final, sinó reforçar la capacitat d'anàlisi de l'equip investigador amb eines quantitatives que prioritzin hipòtesis de manera transparent.

3.2 Machine Learning i explicabilitat per a qualitat de processos

En els darrers anys, l'aplicació de ML en qualitat farmacèutica ha crescut en casos com detecció d'anomalies, manteniment predictiu i predicció de lots fora d'especificació, utilitzant models com *random forest*, *gradient boosting* [5] o xarxes neuronals. Tanmateix, en escenaris RCA regulats, una bona mètrica predictiva és condició necessària però no suficient: cal demostrar robustesa, estabilitat temporal i, especialment, interpretabilitat operativa [7, 22].

Les tècniques XAI (SHAP [15, 14], LIME [21, 20]) han permès avançar en la transformació de

prediccions en hipòtesis investigables, actuant com a mecanisme de **priorització d'hipòtesis** per reduir l'espai de recerca. Diversos treballs destaquen la diferència entre models orientats al rendiment i models interpretable-by-design que, amb compromís moderat en exactitud, faciliten la justificació de resultats i adopció en processos de qualitat.

3.3 Explainable Boosting Machines: estat actual

Els *Explainable Boosting Machines* (EBM) representen una extensió moderna dels *Generalized Additive Models* (GAMs) [9] que combina interpretabilitat nativa amb capacitat predictiva competitiva. Els treballs de Lou et al. [12] i Caruana et al. [4] van establir les bases dels models GA2M (GAMs amb interaccions de parell), demostrant que és possible capturar interaccions controlades mantenint una estructura additiva llegible.

La literatura recent mostra que els EBM assoleixen rendiment comparable a *Random Forest* o *Boosted Trees*, amb l'avantatge d'un funcionament intern directament explicable [16, 18, 1]. A diferència dels models *black box*, l'EBM pertany a la família *glass box* i permet descriure explícitament la contribució de cada variable i interacció a la predicció, facilitant la comunicació amb experts de domini i la seva adopció en contextos on la transparència és crítica.

3.4 Industrialització i validació en entorns GxP

La literatura de regulació digital i validació de sistemes computaritzats (GAMP 5 [10], ALCOA+ [23]) estableix la necessitat de definir l'ús previst, control de canvis, traçabilitat de dades/models i monitoratge continu del rendiment per garantir que una solució ML sigui defensible en auditoria. Diversos treballs destaquen també el risc de *drift* [13] i la necessitat de governança del cicle de vida del model.

Com a síntesi, l'estat de l'art mostra que existeixen peces madures (RCA estructurat, modelització predictiva, XAI, qualitat de dades), però manca sovint una metodologia integral que

les uneixi de forma operativa i compatible amb entorns regulats. Aquesta és precisament la bretxa que aborda el present treball: utilitzar un model interpretable-by-design com l'EBM per prioritzar hipòtesis de causa arrel amb criteris tècnics, traçables i alineats amb requisits GxP.

4 Dades

4.1 Context del dataset

El conjunt de dades integra informació de producció, control de qualitat, sensors de procés i metadades operatives d'un procés de fraccionament de plasma humà. Es disposa de **4.600 lots** al llarg de **9 anys**, amb **150 paràmetres** agrupats en blocs funcionals: variables de procés (temperatura, pressió, temps), qualitat (potència, impureses), context operatiu (torn, operador, equip), manteniment i marques temporals.

El cas d'estudi tracta del procés industrial de fraccionament de plasma humà, que té com a objectiu separar proteïnes terapèutiques de gran valor. Aquest procés es basa en el mètode de fraccionament amb etanol en fred desenvolupat per Cohn, que utilitza canvis controlats de pH, temperatura i concentració d'etanol per separar diferents proteïnes [6, 3]. Tot i que actualment el procés inclou etapes avançades de purificació, el rendiment i la seguretat del producte depenen principalment de les primeres etapes de separació [3].

Aquest treball se centra en la producció fins a l'obtenció de la Fracció II+III, on es concentra la major part de les immunoglobulines (IgG). El tram analitzat inclou tres fases clau: (1) separació inicial, que inclou la descongelació del plasma i la recuperació del crioprecipitat, amb el temps de barreja (*pooling*) i l'edat del plasma com a factors més rellevants; (2) precipitació de proteïnes, on se separen les Fraccions I i II+III mitjançant l'addició d'etanol i l'ajust del pH, etapa en què són crítics la precisió en l'addició d'etanol, el control del pH i el temps de mescla; i (3) filtració i recuperació, que es realitza amb filtres premsa i papers de diferent gruix, i determina el rendiment final (*yield*) i la claredat

del filtrat [3, 6].

El procés és altament variable perquè el plasma és una matèria primera biològica i les proteïnes són especialment sensibles als canvis de temperatura i a les condicions químiques [3, 10]. En aquest context, petites variacions en paràmetres operatius com la pressió de les centrífugues, la quantitat de tampó afegit o el temps de filtració poden afectar directament la recuperació de la IgG i la qualitat del producte final. Per aquest motiu, és necessari utilitzar eines avançades d'anàlisi de causes arrel (RCA), que permetin reduir la variabilitat del procés i prioritzar les investigacions, assegurant el compliment de la normativa GxP.

A partir del **2024** s'observa un canvi de procés que coincideix amb una millora del *yield*. Atesa la no-estacionarietat del procés, l'entrenament es focalitza en dades **des de 2024 (960 lots)** per garantir homogeneïtat operacional. Del total de 150 variables, **104 són numèriques i 46 categòriques**.

4.2 Qualitat de dades, neteja i preparació

La neteja no s'ha fet de manera mecànica, sinó amb criteri de domini i validació experta, alineant-se amb la literatura sobre interpretabilitat i selecció de variables en contextos industrials [17, 8, 11, 2]. S'han analitzat valors absents per variable i causa operacional, correlacions fortes per evitar redundàncies i multicolinealitat, variables de variància baixa amb aportació limitada, i variables temporals amb baixa utilitat causal directa.

S'ha construït un mapa de variables per documentar descripció funcional, fase del procés, naturalesa accionable i relacions entre variables. Cada variable inclou atributs com descripció, fase, accionabilitat i correlacions, facilitant la separació de variables operatives, informatives i descriptives.

També s'han aplicat transformacions de *feature engineering*, substituint marques temporals puntuals per durades agregades més robustes (p. ex. temps total de fase), reduint soroll i concentrant el model en factors rellevants del

comportament de procés.

4.3 Partició temporal i govern de dades

La partició de dades es realitza cronològicament dins del període 2024+ per evitar fuites d'informació. El dataset final conté **956 mostres i 56 variables**. Per garantir traçabilitat *end-to-end*, s'ha establert versionat de datasets, diccionari de dades i registre de transformacions.

5 Metodologia

Aquest treball proposa una metodologia estructurada en cinc capes: anàlisi exploratòria, modelització ML (Lasso, Gradient Boosting, EBM), estratègia *filter-then-interact* amb EBM en tres fases, explicabilitat per a RCA, i validació/industrialització. L'arquitectura garanteix rendiment predictiu i interpretabilitat alineada amb el domini farmacèutic.

5.1 Capa d'anàlisi exploratòria

Activitats d'exploració i comprensió del conjunt de dades:

- **Anàlisi de la distribució de variables:** Estudi de la distribució de la variable objectiu (qualitat de la proteïna) i de les variables predictores.
- **Detecció de valors atípics:** Identificació de dades anòmales que poden afectar el rendiment dels models.
- **Anàlisi de correlacions:** Estudi de les relacions lineals entre variables per detectar redundàncies i possibles col·linealitats.
- **Reducció de dimensionalitat basada en correlació:** Eliminació de variables altament correlacionades per simplificar el model i evitar multicolinealitat.
- **Anàlisi de qualitat de les dades:** Avaluació de la completesa i consistència de les dades, així com la identificació de valors faltants.

5.2 Capa de modelització de ML

Es van avaluar tres famílies de models per establir una línia base:

1. **Lasso (Least Absolute Shrinkage and Selection Operator):** Model lineal amb regularització L1 que realitza selecció de característiques de manera automàtica. Aquest model serveix com a línia base i proporciona una primera aproximació a les variables més rellevants.
2. **Gradient Boosting (XGBoost/LightGBM):** Models d'ensemble basats en arbres de decisió que capturen relacions no lineals complexes. Aquests models ofereixen alt rendiment predictiu però són menys interpretables.
3. **Explainable Boosting Machine (EBM):** Model additiu generalitzat (GAM) basat en boosting que manté la interpretabilitat mentre captura efectes no lineals i interaccions entre variables.

5.2.1 Model de línia base: Lasso

El model Lasso va aconseguir $MAE = 1.126$, $RMSE = 1.646$ i $R^2 = 0.332$ sobre el conjunt de test.

Les variables més rellevants identificades pel Lasso inclouen pes de fraccions específiques (D23, C29) i paràmetres de filtració (D36, D24), establint la base per a l'estratègia amb EBM.

5.3 Estratègia *filter-then-interact* amb EBM

L'estratègia *filter-then-interact* captura efectes principals i interaccions en tres fases progressives, minimitzant overfitting i maximitzant interpretabilitat.

5.3.1 Fase 1: Identificació d'efectes principals

S'entrena un model EBM sense interaccions ($interactions=0$) per capturar únicament els

efectes principals de cada variable.

Els hiperparàmetres utilitzats en aquesta fase són:

- `interactions = 0`
- `learning_rate = 0.05`
- `max_bins = 256`
- `max_rounds = 5000`
- `min_samples_leaf = 2`

El model EBM va aconseguir $MAE = 1.072$, $RMSE = 1.602$ i $R^2 = 0.368$, superant el base-line Lasso i capturant relacions no lineals.




Figura 1: Importància de les característiques en el model EBM Fase 1 (sense interaccions).

5.3.2 Fase 2: Filtrat i reducció de dimensionalitat

Selecció de característiques basada en la importància apresada en Fase 1, reduint dimensionalitat i facilitant captura d'interaccions significatives.

Prova preliminar: Lasso → EBM (Top-10) Es va utilitzar el model Lasso com a filtre inicial, seleccionant les 10 característiques amb major importància per entrenar un model EBM. Resultats a la Taula ??.

El model EBM amb Top-10 Lasso va aconseguir $MAE=1.072$, $RMSE=1.602$, $R^2=0.368$.

La configuració final va seleccionar les **15 característiques més importants** (`top_n = 15`), identificant el punt on la importància experimenta una caiguda significativa i mantenint variables amb major poder predictiu.

5.3.3 Fase 3: Captura controlada d'interaccions

La tercera i última fase entrena un model EBM sobre el conjunt reduït de característiques seleccionades en la Fase 2, activant la detecció automàtica d'interaccions. Aquesta configuració permet que el model identifiqui fins a 25 parells d'interaccions significatives (`interactions=25`) de manera automàtica.

Els hiperparàmetres utilitzats en aquesta fase són:

- `interactions = 10` (detecció automàtica)
- `learning_rate = 0.05`
- `max_bins = 256`
- `max_rounds = 5000`
- `min_samples_leaf = 10`

El model final va aconseguir un rendiment significativament millorat: $MAE = 1.018$, $RMSE = 1.466$ i $R^2 = 0.470$, demostrant l'efectivitat de la captura d'interaccions de manera controlada.

La Figura 2 mostra que el model captura efectes principals robustos i interaccions rellevants entre variables.


5.3.4 Densitat de dades i control de complexitat

La reducció de característiques (de 50+ variables a 15) redueix l'espai de cerca d'interaccions de $O(n^2)$ i garanteix suficients dades per estimar efectes principals i interaccions de manera fiable.


5.4 Capa d'explicabilitat i Root Cause Analysis

Els models EBM proporcionen explicacions a diferents nivells. Tècniques utilitzades:

- **Importància global de característiques:** Mesura de la contribució relativa de cada variable i interacció al rendiment general del model.
- **Shape functions:** Visualització de com cada característica afecta la predicció al llarg del seu rang de valors, capturant relacions no lineals.
- **Contribucions locals:** Descomposició de prediccions individuals per entendre quines variables i interaccions contribueixen a prediccions específiques.
- **Anàlisi d'interaccions:** Exploració de les relacions sinèrgiques entre parells de variables per identificar efectes combinats.



(a) Efectes principals



(b) Interaccions entre variables

Figura 2: Descomposició del model EBM Fase 3: (a) importància dels efectes principals de les 15 característiques seleccionades, (b) importància de les interaccions detectades automàticament pel model.

5.5 Capa de validació i industrialització

Validació rigorosa del model i preparació per a implementació en entorns productius, garantint robustesa davant nous lots de producció.

5.5.2 Validació d'hiperparàmetres i robustesa final

Es van explorar set configuracions diferents, variant bins (128, 256, 512), mostres per fulla (2, 5, 10), interaccions (15, 20, 25) i profunditat d'aprenentatge, identificant la configuració amb millor equilibri entre precisió, estabilitat i robustesa. Resultats detallats a la Secció 6.

5.5.3 Preparació per a la industrialització

Aspectes clau: serialització i versionat del model (pickle/joblib amb metadades), pipeline de preprocessament documentat, sistema de monitoratge per detectar *data/model drift*, integració amb sistemes MES via API REST, i documentació tècnica i operativa completa.

6 Resultats i Discussió

6.1 Configuració experimental

Tots els experiments s'han executat amb Python 3.9, InterpretML 0.4.3, scikit-learn 1.2.0, validació creuada de 5 folds (seed=42) sobre un dataset de **956 mostres i 56 variables**. Les mètriques emprades són MAE (Mean Absolute Error), RMSE (Root Mean Squared Error) i R^2 (Coefficient of Determination), calculades amb mitjana i desviació estàndard per avaluar estabilitat.

6.2 Resultats quantitatius i millora progressiva

La Taula 1 mostra la millora progressiva des del model baseline Lasso fins a la millor configuració de Fase 4, demostrant l'efectivitat de la metodologia proposada.

Taula 1: Evolució progressiva del rendiment del model a través de les fases de la metodologia.

Fase	MAE	RMSE	R^2
Lasso (Baseline)	1.126	1.646	0.332
EBM Fase 1	1.072	1.602	0.368
EBM Fase 3	1.018	1.466	0.470
EBM Fase 4 (Robust)	0.950	1.368	0.422
Millora total (%)	-15.6%	-16.9%	+27.1%

S'ha aconseguit una reducció del **15.6% en MAE** i del **16.9% en RMSE**, amb increment del 27.1% en R^2 . Cal destacar que la Fase 3 obté un R^2 superior (0.470) però amb menys estabilitat. La configuració **Robust (Leaf=10)** de Fase 4 ofereix el millor compromís entre precisió i robustesa: MAE=0.950, RMSE=1.368, R^2 =0.422, amb desviacions estàndard contingudes que garanteixen estabilitat entre folds. Aquesta robustesa és crítica per a aplicació industrial, on la fiabilitat és tan important com la precisió puntual.

6.3 Comparació de configuracions en Fase 4

S'han avaluat set configuracions d'EBM en Fase 4, explorant diferents compromisos entre preci-

sió, interpretabilitat i robustesa. La Taula 2 mostra els resultats.

Taula 2: Resultats de les set configuracions d'EBM en Fase 4 amb 5-fold cross-validation.

Configuració	MAE $\pm$ std	RMSE $\pm$ std	R^2 $\pm$ std
Robust (Leaf=10)	0.950 $\pm$ 0.063	1.368 $\pm$ 0.153	0.422 $\pm$ 0.109
High Interactions (25)	0.953 $\pm$ 0.057	1.370 $\pm$ 0.136	0.421 $\pm$ 0.094
Current Best	0.953 $\pm$ 0.060	1.371 $\pm$ 0.154	0.420 $\pm$ 0.107
High Precision (512 bins)	0.954 $\pm$ 0.059	1.371 $\pm$ 0.149	0.420 $\pm$ 0.103
Slow/Deep Learning	0.954 $\pm$ 0.068	1.381 $\pm$ 0.155	0.412 $\pm$ 0.105
Smooth Sensors (128 bins)	0.956 $\pm$ 0.059	1.378 $\pm$ 0.149	0.415 $\pm$ 0.101
Simple/Stable	0.963 $\pm$ 0.069	1.411 $\pm$ 0.162	0.387 $\pm$ 0.108

Les configuracions amb més regularització (Robust, Current Best) superen les més complexes, confirmant que amb datasets limitats (956 mostres) la simplificació del model és més beneficiosa que l'increment de capacitat representacional.

6.4 Interpretació dels resultats i utilitat per a RCA

L'anàlisi mostra que el guany predictiu prové de la combinació d'efectes principals i interaccions rellevants, no d'una única variable dominant. Els factors més crítics identificats inclouen variables de condicions de tanc, temps de mescla, configuracions de filtració i estructura operativa del lot. Les interaccions més rellevants combinen variables de preparació i filtració, explicant comportaments no lineals impossibles de captar amb models lineals.

Des d'una perspectiva operativa, la metodologia redueix l'espai de recerca des del conjunt ampli de variables originals cap a un subconjunt prioritari, facilitant: (1) reducció de complexitat inicial en investigacions RCA; (2) generació d'hipòtesis accionables amb impacte mesurable; (3) traçabilitat de decisions vinculada a evidència quantitativa.

6.4.1 Impacte operatiu i econòmic del model

La utilitat de la metodologia proposada rau en la seva capacitat per quantificar el cost d'oportunitat de les desviacions i prioritzar accions de millora basades en evidència quantitativa. Per fonamentar la validesa d'aquestes projeccions, s'ha utilitzat el model configurat com a

Robust (Leaf=10). L'aplicació d'una estratègia de validació creuada de 5 folds suggereix una estabilitat adequada en les mètriques de rendiment ($R^2=0.422$ i $MAE=0.950 \pm 0.063$), redueix el risc de sobreajustament i mostra estabilitat fora de mostra, indicant una capacitat de generalització moderada.

Metodologia d'estimació del potencial optimitzat. A diferència dels models de caixa negra, l'arquitectura nativament interpretable de l'EBM permet descompondre cada predicció individual com una suma algebraica de contribucions:

$$f(x) = \beta_0 + \sum_i f_i(x_i) + \sum_{i,j} f_{ij}(x_i, x_j).$$

Aquesta propietat s'ha utilitzat per identificar, lot a lot, el cost d'oportunitat vinculat a variables operatives subòptimes. El potencial optimitzat de cada lot, Y_{opt} , es calcula segons l'expressió següent:

$$Y_{opt} = Y_{pred} + (-Score_{neg} \cdot rec \cdot R^2).$$

On $Score_{neg}$ representa la suma de les contribucions negatives identificades pel model (factors amb impacte inferior a -0.1 punts percentuals), i rec és un factor de recuperació operativa fixat en el 70%. Aquesta penalització del 30% en la recuperació, sumada a la ponderació per la variància explicada ($R^2 = 0.422$), constitueix un coeficient de conservadorisme global aproximat del 29.4%, que integra les limitacions de controlabilitat en planta i les possibles interaccions no lineals no capturades.

Aquest coeficient no és arbitrari, sinó que respon a la integració de dues limitacions fonamentals: (1) **variància explicada** ($R^2 = 0.422$), que actua com a factor de confiança estadística, assumint que només es pot intervenir sobre la fracció de variabilitat que el model és capaç de capturar; i (2) **recuperabilitat operativa** ($rec = 0.70$), que aplica una penalització del 30% per considerar les friccions reals de la planta, com el temps de resposta, la precisió dels equips i les inèrcies del procés. Això reconeix que l'optimització teòrica rarament és assolible al 100% en entorns GxP. Cal destacar que les contribucions del model s'interpreten com a senyals direccionals associatius, i no com a efectes causals directes sobre el rendiment.

Escenari A: potencial total d'optimització del portfoli. L'anàlisi de la cartera sobre els lots del període post-canvi revela que la producció presenta oportunitats d'optimització en alguns dels seus paràmetres. En aquest escenari ideal, on es corregirien tots els factors operatius que el model identifica com a *negative drivers*, s'estima un increment del rendiment mitjà (D49) del 46.31% al 47.32%. Aquest guany absolut de +1.01 punts percentuals, equivalent a una millora relativa del 2.2%, suposaria un increment mitjà de facturació de 268.000 \$ per lot produït, assumint un preu de referència de 55 \$/g. En el conjunt del portfoli analitzat, l'oportunitat total ascendeix a 259 milions de dòlars, associats a 4.703 kg de proteïna addicional, amb un impacte recurrent estimat de 26.8 milions de dòlars anuals per a una cadència de 100 lots. Aquest escenari s'ha d'interpretar com un horitzó aspiracional, ja que l'optimització simultània de totes les variables pot veure's limitada per interaccions no lineals o restriccions físiques de la instal·lació.

Escenari B: optimització focalitzada d'alt retorn. Atès que una intervenció sobre totes les variables pot ser complexa operativament, el model permet identificar una ruta d'optimització simplificada, focalitzada en només tres variables crítiques: D36, paràmetre de filtració que afecta el 62.1% dels lots; D24, associada a mescla i present en el 50.4% dels lots; i D40, associada a filtració i present en el 43.0% dels lots. Aquesta intervenció selectiva permetria capturar de forma immediata un guany de +0.19 punts percentuals de rendiment, aproximadament el 19% del potencial total del model. Tot i semblar una xifra modesta en termes percentuals, en el context de l'alt valor de la proteïna C activada, aquesta millora focalitzada generaria per si sola uns ingressos addicionals propers als 5 milions de dòlars anuals, justificant la inversió en el sistema de decisió assistida amb un esforç d'ajustament mínim en planta.

Metodologia de càlcul i conservadorisme. Per garantir la robustesa d'ambdós escenaris davant d'auditories de qualitat, s'ha aplicat un factor de conservadorisme global del 29.4%. Aquest coeficient no és una agregació lineal de

magnituds heterogènies, sinó un filtre en cascada que diferencia la confiança estadística de la viabilitat operativa, seguint principis de prudència en la gestió de riscos en projectes de qualitat biofarmacèutica [19]. La confiança del model ($R^2 = 0.422$) actua com a primer tall de prudència, assumint que només és possible intervenir sobre la fracció de variabilitat que el model és capaç d'explicar formalment. La recuperabilitat operativa ($rec = 0.70$) aplica una penalització del 30% per absorbir les inèrcies físiques de la planta i els marges de seguretat GxP, reconeixent que l'òptim teòric és difícilment assolible en la pràctica. Finalment, l'error absolut mitjà (MAE=0.950) s'utilitza com a referència per filtrar les recomanacions, de manera que el cas de negoci es basi en senyals robustos i no en fluctuacions aleatòries.

Aquesta estructura modular permet justificar que les estimacions no són meres projeccions algorítmiques, sinó un escenari de negoci ajustat a la realitat física i estadística de l'entorn de producció. En aquest sentit, el model actua com un sistema de priorització de decisions operatives basat en evidència, i no com un optimitzador automàtic del procés.

Com a tancament d'aquesta metodologia, i per avaluar la robustesa del cas de negoci davant d'entorns canviants, s'ha analitzat la sensibilitat del projecte davant variacions en les principals hipòtesis econòmiques. Pel que fa al preu base de 55 \$/g, una variació de $\pm 10\%$ té un impacte proporcional sobre els ingressos estimats, equivalent aproximadament a ± 26.800 \$ per lot i ± 2.68 milions de dòlars anuals. En tots els casos, el projecte manté una contribució econòmica significativa, indicant una baixa sensibilitat a fluctuacions moderades de mercat. També s'han considerat tres escenaris orientatius d'inversió: un escenari conservador d'aproximadament 1 milió de dòlars anuals, amb retorn altament favorable i immediat; un escenari intermedi d'aproximadament 5 milions de dòlars anuals, en què el cas de negoci continua sent clarament positiu i justificaria per si sol l'estratègia focalitzada de l'Escenari B; i un escenari exigent d'aproximadament 15 milions de dòlars anuals, en què el projecte manté un retorn net positiu, tot i la reducció lògica del marge.

En conjunt, l'anàlisi confirma que el *business*

case mostra una robustesa elevada davant les variacions de preu i una sensibilitat moderada al cost d'implementació. Aquest últim és el principal factor de variabilitat en la rendibilitat final, però no compromet la viabilitat financera del projecte.

Un resultat rellevant és que la interpretabilitat s'obté de manera *nativa* amb EBM, no com capa post-hoc. Això implica que les contribucions per variable formen part intrínseca de la predicció, amb descomposició exacta del valor estimat. En comparació amb tècniques post-hoc (SHAP, LIME), l'enfocament natiu redueix inconsistències i simplifica la comunicació amb equips de procés i qualitat [14, 20, 22].

6.5 Comparació amb RCA tradicional i limitacions

L'enfoc data-driven aporta consistència entre casos, velocitat en priorització i capacitat de tractar múltiples variables simultàniament. Tanmateix, l'RCA tradicional manté fortaleeses en profunditat causal contextual i integració de coneixement tàcit. La proposta més robusta és una estratègia *human-in-the-loop*: el model estructura i prioritza l'evidència; l'equip expert valida, contrasta i decideix accions finals.

Limitacions identificades: (1) dataset efectiu acotat a 956 mostres; (2) dependència de qualitat de registre; (3) risc de *drift* amb canvis operatius [13]; (4) lectura causal limitada per natura observacional; (5) bretxa d'implementació per integració GMP/QMS. El model és un *decision support system*, no substitut de revisió experta.

7 Conclusions i Treball Futur

Aquest treball demostra la viabilitat tècnica i operativa d'una metodologia d'industrialització de la Root Cause Analysis basada en models ML interpretables en entorns farmacèutics regulats. La proposta integra preparació de dades, modelització per fases, explicabilitat nativa i criteris de validació en un marc coherent, reproducible i orientat a decisió.

Conclusions principals:

- L'estratègia *filter-then-interact* amb EBM millora consistentment el rendiment respecte al baseline Lasso (reducció 15.6% MAE, 16.9% RMSE).
- La configuració **Robust (Leaf=10)** ofereix el millor compromís entre precisió (MAE=0.950), estabilitat i aplicabilitat industrial, prioritzant robustesa davant R^2 lleugerament inferior a Fase 3.
- La interpretabilitat nativa d'EBM facilita la prioritització de causes potencials i accelera la formulació d'hipòtesis RCA, reduint l'espai de recerca i millorant l'eficiència investigadora.
- El sistema és especialment útil com a eina de suport en contextos de producció amb alta exigència de traçabilitat, connectant potencial analític del ML amb necessitats operatives de qualitat farmacèutica.

Tanmateix, la industrialització completa requereix consolidar validació en entorn real, desplegar monitoratge continu de *drift* i establir governança formal del cicle de vida del model.

Línies de treball futur:

- **Validació formal GxP:** executar IQ/OQ/PQ i integrar en cicle de validació corporatiu.
- **Ampliació i qualitat de dades:** incrementar cobertura temporal i validar en nous escenaris de producció.
- **Monitoratge i governança:** desplegar seguiment de deriva, versionat, protocols de recalibratge i reentrenament amb aprovacions QA.
- **Integració operativa:** connectar prioritització RCA amb fluxos de desviacions, CAPA i sistemes MES/LIMS.

Com a conclusió final, la proposta constitueix una base sòlida, escalable i auditable per a la implantació progressiva d'un sistema RCA assistit per ML en entorns regulats, confirmant que és possible evolucionar des d'un RCA qualitatiu cap a un enfoc híbrid, sistemàtic i data-driven, mantenint l'expertesa humana com a element central de validació i decisió final.

Referències

- [1] Anonymous. Recent advances and evaluation trends in explainable boosting machines, 2025. arXiv:2512.00528.
- [2] Verónica Bolón-Canedo and et al. A review of feature selection methods on synthetic data. *arXiv preprint arXiv:1507.08492*, 2015.
- [3] Thierry Burnouf. Modern plasma fractionation. *Transfusion Medicine Reviews*, 21(2):101–117, 2007.
- [4] Rich Caruana, Yin Lou, Johannes Gehrke, Paul Koch, Marc Sturm, and Noemie Elhadad. Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2015.
- [5] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [6] E. J. Cohn, L. E. Strong, W. L. Hughes, D. J. Mulford, J. N. Ashworth, M. Melin, and H. L. Taylor. Preparation and properties of serum and plasma proteins. iv. a system for the separation into fractions of the protein and lipoprotein components of biological tissues and fluids. *Journal of the American Chemical Society*, 68(3):459–475, 1946.
- [7] Finale Doshi-Velez and Been Kim. Towards a rigorous science of interpretable machine learning. *arXiv preprint arXiv:1702.08608*, 2017.
- [8] Isabelle Guyon and Andre Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003.
- [9] Trevor J. Hastie and Robert J. Tibshirani. *Generalized Additive Models*. Chapman and Hall, 1990.

- [10] ISPE. *GAMP 5: A Risk-Based Approach to Compliant GxP Computerized Systems*. International Society for Pharmaceutical Engineering, 2022.
- [11] et al. Liu. Investigating and imputing missing data in industrial datasets. *arXiv preprint arXiv:2106.12345*, 2021.
- [12] Yin Lou, Rich Caruana, Johannes Gehrke, and Giles Hooker. Accurate intelligible models with pairwise interactions. In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2013.
- [13] Jie Lu, Anjin Liu, Fan Dong, Feng Gu, João Gama, and Guangquan Zhang. Learning under concept drift: A review. *arXiv preprint arXiv:2004.05785*, 2020.
- [14] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *arXiv preprint arXiv:1705.07874*, 2017.
- [15] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 2017.
- [16] Harsha Nori, Samuel Jenkins, Paul Koch, and Rich Caruana. Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019.
- [17] Harsha Nori, Samuel Jenkins, Paul Koch, and Rich Caruana. A unified framework for machine learning interpretability. *arXiv preprint arXiv:1909.09223*, 2019.
- [18] PiML Team. Piml toolbox: Explainable boosting machine (ebm) guide. https://selfexplainml.github.io/PiML-Toolbox/_build/html/guides/models/ebm.html, 2025.
- [19] Anurag S. Rathore and Helen Winkle. Quality by design for biopharmaceuticals. *Nature Biotechnology*, 27(1):26–34, 2009.
- [20] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "why should i trust you?": Explaining the predictions of any classifier. *arXiv preprint arXiv:1602.04938*, 2016.
- [21] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "why should i trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [22] Cynthia Rudin, Ching-Hsiang Chen, Zhi Chen, Han Huang, Lesia Semenova, and Chudi Zhong. Interpretable machine learning: Fundamental principles and 10 grand challenges. *arXiv preprint arXiv:2103.11251*, 2021.
- [23] U.S. Food and Drug Administration. *Data Integrity and Compliance With Drug CGMP: Questions and Answers Guidance for Industry*. FDA, 2018.